Задача оптимизации

$$\min_{\substack{g_i(x) \& 0, \\ i=1,\dots,m, \\ x \in Q}} f(x) \tag{1}$$

- ullet $Q\subseteq \mathbb{R}^d$ подмножество d-мерного пространства
- ullet $f:Q o \mathbb{R}$ некоторая функция, заданная на множестве Q
- В качестве & берётся ≤, ≥ либо =
- ullet $g_i(x):Q o \mathbb{R},\ i=1,\ldots,m$ функции, задающие ограничения

Матрица Гессе [править | править код]

Матрица этой квадратичной формы образована вторыми частными производными функции. Если все производные существуют, то

Определитель этой матрицы называется **определителем Гессе**, или просто **гессианом**[источник не указан 3595 дней]

Матрицы Гессе используются в задачах оптимизации методом Ньютона. Полное вычисление матрицы Гессе может быть затруднительно, поэтому были разработаны квазиньютоновские алгоритмы, основанные на приближённых выражениях для матрицы Гессе. Наиболее известный из них — алгоритм Бройдена — Флетчера — Гольдфарба — Шанно.

Примеры задач оптимизации. Логистическая регрессия.

$$\min_{x \in \mathbb{R}^d} \left\{ f(x) = \frac{1}{n} \sum_{i=1}^n \log \left(1 + \exp \left(-y_i \cdot (\mathbf{A}x)_i \right) \right) \right\},\tag{2}$$

- $\mathbf{A} \in \mathbb{R}^{n \times d}$ матрица признаков, n количество объектов $x \in \mathbb{R}^d$ вектор параметров, d количество параметров
- $y \in \{-1,1\}^n$ вектор ответов
- ullet ($oldsymbol{A}x$) $_{i},y_{i}-i$ -е компоненты векторов $oldsymbol{A}x$ и y соответственно

Данная задача возникает как один из подходов к решению задачи бинарной классификации.

Задачи оптимизации. Первые наблюдения.

- В общем случае задачи оптимизации могут не иметь решения. Например, задача $\min_{x \in \mathbb{R}} x$ не имеет решения.
- 2 Задачи оптимизации часто нельзя решить аналитически.
- может зависеть от размерности x.

Если же задача оптимизации имеет решение, то на практике её обычно решают, вообще говоря, приближённо. Для этого применяются специальные алгоритмы, которые и называют методами оптимизации.

Методы оптимизации I

- Нет смысла искать лучший метод для решения конкретной задачи. Например, лучший метод для решений задачи $\min_{x \in \mathbb{R}^d} \|x\|^2$ сходится за 1 итерацию: этот метод просто всегда выдаёт ответ $x^* = \mathbf{0}$. Очевидно, что для других задач такой метод не пригоден.
- Эффективность метода определяется для класса задач, т.к. обычно численные методы разрабатываются для *приближённого* решения множества однотипных задач.
- Метод разрабатывается для класса задач ⇒ метод не может иметь с самого начала полной информации о задаче. Вместо этого метод использует модель задачи, например, формулировку задачи, описание функциональных компонент, множества, на котором происходит оптимизация и т.д.

Методы оптимизации II

 Предполагается, что численный метод может накапливать специфическую информацию о задаче при помощи некоторого оракула. Под оракулом можно понимать некоторое устройство, которое отвечает на последовательные вопросы численного метода.

Примеры оракулов

- Оракул нулевого порядка в запрашиваемой точке x возвращает значение целевой функции f(x).
- Оракул первого порядка в запрашиваемой точке возвращает значение функции f(x) и её градиент в данной точке $\nabla f(x) = \left(\frac{\partial f(x)}{\partial x_1}, \dots, \frac{\partial f(x)}{\partial x_n}\right)$.

Общая итеративная схема метода оптимизации ${\cal M}$

Входные данные: начальная точка x^0 (0 — верхний индекс), требуемая точность решения задачи $\varepsilon > 0$. Настройка. Задать k = 0 (счётчик итераций) и $I_{-1} = \varnothing$ (накапливаемая информационная модель решаемой задачи). Основной цикл

- $oldsymbol{0}$ Задать вопрос к оракулу \mathcal{O} в точке x^k .
- **2** Пересчитать информационную модель: $I_k = I_{k-1} \cup (x_k, \mathcal{O}(x^k))$.
- **3** Применить правило метода ${\cal M}$ для получения новой точки x^{k+1} по модели I_k .
- **4** Проверить критерий остановки $\mathcal{T}_{\varepsilon}$. Если критерий выполнен, то выдать ответ \bar{x} , иначе положить k:=k+1 и вернуться на шаг 1.

Сложность методов оптимизации

- Аналитическая сложность число обращений к оракулу, необходимое для решения задачи с точностью ε .
- Арифметическая сложность общее число вычислений (включая работу оракула), необходимых для решения задачи с точностью ε .

Примеры итерационных методов. Градиентный спуск

Рассмотрим задачу оптимизации

$$\min_{x \in \mathbb{R}^d} f(x), \tag{5}$$

где функция f(x) дифференцируема. Предположим, что в любой точке мы можем посчитать её градиент.

Алгоритм 1 Градиентный спуск с постоянным размером шага

Вход: размер шага $\gamma>0$, стартовая точка $x^0\in\mathbb{R}^d$, количество итераций N

- 1: for k = 0, 1, ..., N-1 do
- 2: Вычислить $\nabla f(x^k)$
- 3: $x^{k+1} = x^k \gamma \nabla f(x^k)$
- 4: end for

Выход: x^N

Примеры итерационных методов. Метод Ньютона

Рассмотрим задачу оптимизации

$$\min_{\mathbf{x} \in \mathbb{R}^d} f(\mathbf{x}),\tag{6}$$

где функция f(x) дважды непрерывно дифференцируема. Предположим, что в любой точке мы можем посчитать её градиент и матрицу вторых производных $\nabla^2 f(x)$.

Алгоритм 2 Метод Ньютона

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, количество итераций N

- 1: **for** k = 0, 1, ..., N 1 **do**
- 2: Вычислить $\nabla f(x^k)$ и $\nabla^2 f(x^k)$
- 3: $x^{k+1} = x^k (\nabla^2 f(x^k))^{-1} \nabla f(x^k)$
- 4: end for

Выход: x^N

Сложность задач оптимизации. Класс задач минимизации липшицевых функций

$$\min_{x \in B_d} f(x) \tag{7}$$

- $B_d = \{x \in \mathbb{R}^d \mid 0 \le x_i \le 1, \quad i = 1, ..., d\}$
- ullet Функция f(x) является M-липшицевой на B_d относительно ℓ_∞ -нормы:

$$\forall x, y | f(x) - f(y) | \le M ||x - y||_{\infty} = M \max_{i=1,...,d} |x_i - y_i|.$$
 (8)

Определение [править | править код]

Отображение f метрического пространства $(X, \, \rho_X)$ в метрическое пространство $(Y, \, \rho_Y)$ называется липшицевым, если найдётся такая константа L (константа Липшица этого отображения), что $\rho_Y(f(x), \, f(y)) \leqslant L \cdot \rho_X(x, \, y)$ при любых $x, \, y \in X$. Это условие называют условием Липшица. Отображение с L=1 (1-липшицево отображение) называют также коротким отображением.

Липшицево отображение $f{:}X o Y$ называется **билипшицевым**, если у него существует обратное $f^{-1}{:}Y o X$, которое также является липшицевым.

Отображение $f: X \to Y$ называется **колипшицевым**, если существует константа L такая, что для любых $x \in X$ и $y \in Y$ найдётся $x' \in f^{-1}(y)$ такое, что $\rho_Y(f(x), y) \leqslant L \cdot \rho_X(x, x')$.

Сложность задач оптимизации. Класс задач минимизации липшицевых функций

Наблюдение

Множество B_d является ограниченным и замкнутым, т.е. компактом, а из липшицевости функции f следует и её непрерывность, поэтому задача (7) имеет решение, ибо непрерывная на компакте функция достигает своих минимального и максимального значений. Пусть $f_* = \min_{x \in B_d} f(x)$.

- Класс методов. Для данной задачи рассмотрим методы нулевого порядка.
- Цель: найти $\bar{x} \in B_d$: $f(\bar{x}) f_* \le \varepsilon$.

Сложность задач оптимизации. Класс задач минимизации липшицевых функций

Рассмотрим один из самых простых способов решения этой задачи — метод равномерного перебора.

Алгоритм 3 Метод равномерного перебора

Вход: целочисленный параметр перебора $p \geq 1$

- 1: Сформировать $(p+1)^d$ точек вида $x_{(i_1,\ldots,i_d)}=\left(\frac{i_1}{p},\frac{i_2}{p},\ldots,\frac{i_d}{p}\right)^{\top}$, где $(i_1,\ldots,i_d)\in\{0,1,\ldots,p\}^n$
- 2: Среди точек $x_{(i_1,\ldots,i_d)}$ найти точку \bar{x} с наименьшим значением целевой функции f.

Выход: $\bar{x}, f(\bar{x})$

Сложность задач оптимизации. Класс задач минимизации липшицевых функций

Теорема 1 (Теорема 1.1.1 из книги Нестерова 2010 года)

Алгоритм 3 с параметром p возвращает такую точку \bar{x} , что

$$f(\bar{x}) - f_* \le \frac{M}{2p},\tag{9}$$

откуда следует, что методу равномерного перебора нужно в худшем случае

$$\left(\left|\frac{M}{2\varepsilon}\right|+2\right)^d\tag{10}$$

обращений к оракулу, чтобы гарантировать $f(\bar{x}) - f_* \leq \varepsilon$.

Сложность задач оптимизации. Класс задач минимизации липшицевых функций

- Предположим M=2, d=13 И $\varepsilon=0.01$, то есть размерность задачи сравнительно небольшая и точность решения задачи не слишком высокая.
- Необходимое число обращений к оракулу: $\left(\left|\frac{M}{2\varepsilon}\right|+2\right)^d=102^{13}>10^{26}.$
- Сложность оракула при этом составляет не меньше d=13 арифметических операций.
- Производительность компьютера: 10¹¹ арифметических операций в секунду.
- Общее время: хотя бы 10¹⁶ секунд, что больше 300 миллионов лет.

Выпуклые и гладкие функции

Хорошие новости:

- Богатая и интересная теория
- Существуют эффективные алгоритмы приближённого решения

Плохие новости:

- Класс выпуклых и гладких задач не очень широк
- На практике часто приходится сталкиваться с невыпуклыми задачами

Тем не менее, иногда методы выпуклой гладкой оптимизации хорошо себя проявляют на практике и на невыпуклых или негладких задачах, имеющих локальную выпуклость или гладкость, поэтому имеет смысл для начала разобраться, как они работают для выпуклых и гладких задач.

Выпуклые множества

Определение 1

Множество $Q\subseteq \mathbb{R}^d$ называется выпуклым, если для любых двух точек $x,y\in Q$ и для любого числа $\alpha\in [0,1]$ точка $z=\alpha x+(1-\alpha)y$ принадлежит множеству Q.

Это означает, что вместе с любыми двумя точками во множестве содержится и отрезок, их соединяющий.

Выпуклые функции

Определение 2

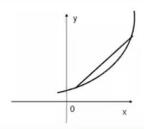
Функция f(x) заданная на **выпуклом** множестве $Q \subseteq \mathbb{R}^d$ называется **выпуклой**, если для любых двух точек $x,y \in Q$ и для любого числа $\alpha \in [0,1]$ выполняется следующее неравенство:

$$f(\alpha x + (1 - \alpha)y) \le \alpha f(x) + (1 - \alpha)f(y). \tag{12}$$

(если знак < для всех $x \neq y, \ \alpha \in (0,1)$, то **строго выпуклой**)

В одномерном случае это означает, что между любыми двумя точками $x, v \in Q$ график функции f проходит

точками $x, y \in Q$ график функции f проходит не выше отрезка, соединяющего f(x) и f(y).



Сильно выпуклые функции

Определение 3

Функция f(x) заданная на выпуклом множестве $Q\subseteq \mathbb{R}^d$ называется μ -сильно выпуклой, если для любых двух точек $x,y\in Q$ и для любого числа $\alpha\in[0,1]$ выполняется следующее неравенство:

$$f(\alpha x + (1 - \alpha)y) \le \alpha f(x) + (1 - \alpha)f(y) - \alpha(1 - \alpha)\frac{\mu}{2}||x - y||_2^2.$$
 (13)

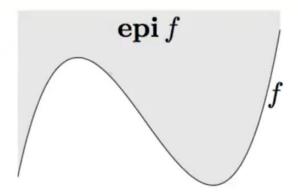
График (строго) выпуклой функции лежит (строго) выше касательной гиперплоскости, а для сильно выпуклой функции график лежит выше некоторого параболоида.

Свойства выпуклых функций I

- Выпуклые функции непрерывны во всех внутренних точках области определения.
- Опльно выпуклая функция, очевидно, строго выпукла. Обратное неверно.
- ③ Функция выпуклая, тогда и только тогда, когда её надграфик (эпиграф) выпуклое множество, где под надграфиком функции f, определённой на множестве $Q \subseteq \mathbb{R}^d$, понимается следующее множество:

$$\operatorname{epi} f = \{(x, t) \mid x \in Q, \ t \in \mathbb{R}, \ t \ge f(x)\} \subseteq \mathbb{R}^{d+1}$$

Свойства выпуклых функций II



4 Если f(x) выпуклая функция, то множество

$$C_{\gamma} = \{ x \in Q \subseteq \mathbb{R}^d \mid f(x) \le \gamma, \ \gamma = const \}$$

является выпуклым.

Свойства выпуклых функций III

$$f\left(\sum_{i=1}^n \lambda_i x_i\right) \leq \sum_{i=1}^n \lambda_i f(x_i)$$

для любых $\lambda_i \geq 0$ и $\sum\limits_{i=1}^n \lambda_i = 1.$

Неравенство Йенсена обобщается и на случай выпуклой комбинации бесконечного (счетного или несчетного) числа точек.